

PUC-Rio

Pontifícia Universidade Católica do Rio de Janeiro



MVP

Pós-graduação em Ciência de Dados e *Analytics*

Estudo da cobertura vacinal do Sarampo no Brasil ao longo dos anos

Aluna: Marina Araujo Gonzaga

E-mail: maargo.1995@gmail.com

Github: <https://github.com/maweet>

Sprint: Engenharia de Dados (40530010057_20260_01)

Sumário

Introdução.....	3
Contexto do Negócio e perguntas.....	3
Dados	4
Fonte dos dados	4
Coleta dos dados.....	4
DataSUS – Cobertura Vacinal.....	4
SIDRA/IBGE – PIB	5
Carga dos dados.....	5
Bronze.....	5
Modelagem e Catálogo de dados.....	9
Silver.....	9
Gold	10
Pipeline de Dados	12
Qualidade de dados.....	13
Análise de Dados	14
Respondendo as questões levantadas	18
Autoavaliação	20
Referências	21

Introdução

Contexto do Negócio e perguntas

A vacinação é extremamente importante para a sociedade. Esta medida reduz diversas patologias causadas por vírus e bactérias, através da estimulação e fortificação do sistema imunológico. Além disso, ajuda na redução da circulação de doenças na população, além de proteger pessoas que não podem ser vacinadas. No passado, doenças como sarampo e poliomielite foram controladas no Brasil, prevenindo maiores hospitalizações, sequelas e mortes.

Portanto, a cobertura vacinal é de suma importância para a saúde pública e, da mesma forma, imprescindível para o governo, uma vez que diminui os gastos públicos com remédios, leitos, consultas, entre outros. O objetivo deste trabalho é analisar como a cobertura vacinal de uma determinada vacina evoluiu ao longo dos anos no Brasil e identificar em quais regiões ela foi mais precária.

Os questionamentos levantados para esse MVP foram divididos em: uma pergunta principal e outras perguntas secundárias. Inicialmente a questão focou na cobertura vacinal do sarampo, devido ao recente aumento de casos confirmados em São Paulo, onde antes era erradicado. Porém, em razão da prevenção do sarampo ser por meio de vacinas combinadas (ou seja, aquelas que protegem contra mais de uma doença em uma aplicação), a análise envolverá a cobertura da tríplice viral SCR (sarampo, caxumba e rubéola) e da tetraviral SCRv (sarampo, caxumba, rubéola e varicela [catapora]):

- **Principal:**
 - Como se deu a evolução da cobertura vacinal contra o sarampo no Brasil ao longo dos anos?
- **Secundárias:**
 - Quais Estados apresentaram maiores e menores índices de vacinação ao longo do período?
 - Quais regiões brasileiras tiveram uma cobertura vacinal mais precária?
 - Quais anos a cobertura vacinal brasileira ficou abaixo da estabelecida para vacinação?
 - Quais diferenças são observadas entre SCR D1, SCR D2 e SCRvZ?
 - Houve períodos de quedas seguidas na cobertura vacinal no Brasil?
 - Análise dos PIBs das regiões e/ou Estado em relação à cobertura da vacinação.

As três últimas perguntas foram feitas conforme evolução do MVP, durante a realização das pesquisas e algumas análises prévias com os dados obtidos.

Dados

Fonte dos dados

Para responder os questionamentos acima, foram utilizados dados oficiais do governo:

- [DataSUS](#): Site onde é possível a extração da cobertura de imunização por região, Unidade Federativa e município, utilizando anos e tipo de vacina.
Vacinas: Tríplice Viral D1 (1ª dose), Tríplice Viral D2 (2ª dose) e Tetra Viral (SCR + VZ)
Períodos: 1999 a 2022 para Tríplice Viral D1 e 2013 a 2022 para as demais.
- [SIDRA/IBGE](#): Site onde é possível a extração de diversos dados relacionados ao
Produto Interno Bruto dos Municípios.
Períodos: 2002 a 2023

Coleta dos dados

DataSUS – Cobertura Vacinal

Para fazer a comparação das vacinas e seus períodos se fez necessário as extrações distintas entre região, unidade federativa e município, uma vez que a unidade de medida da tabela é porcentagem sendo representada pela seguinte fórmula:

$$Cobertura\ Vacinal\ (\%) = \frac{n^{\circ}\ dose\ aplicadas}{população\ alvo} \times 100$$

Ao longo da coleta de dados foi compreendido que não era possível apenas fazer uma média simples para agregar a cobertura vacinal por regiões e estados através do código do município, visto que é uma razão baseada no número de doses aplicadas e população alvo. Logo, foram extraídas nove tabelas do DataSUS que envolvem as coberturas vacinais dos municípios, Unidade Federativa e região para cada uma das vacinas citadas anteriormente.

SIDRA/IBGE – PIB

Para responder a questão sobre o PIB, buscou-se o Produto Interno Bruto disponibilizado pelo IBGE através da SIDRA. Foi obtido o PIB a preços correntes (Mil Reais) de 2002 a 2023 para os Municípios. Nesse caso, podíamos fazer a soma dos PIBs de cada município por código UF também disponibilizado.

Observação: Tanto o SIDRA quanto o DataSUS possuíam a coluna “código do município”, mas notou-se logo na etapa de cargas que o SIDRA possuía 7 dígitos e o DataSUS 6 dígitos. Através do Manual Módulo de Controle Externo – MCE SIOPS referente ao DataSUS encontrou-se a justificativa abaixo para a ausência do sétimo dígito:

Para identificar os Entes da Federação, o SIOPS utiliza o código do IBGE, com uma pequena particularidade, o código do IBGE é composto por sete dígitos e o SIOPS utiliza apenas os seis primeiros dígitos. Ex.: o código do Município do Rio de Janeiro é 3304557, no SIOPS é: 330455.[...]. (BRASIL, 2015, p. 41).


Carga dos dados

Bronze

Foi decidido separar a evolução do MVP em notebooks diversos, contando com bronze_ingestão e bronze_qualidade. Com o desenvolvimento do MVP conforme citado anteriormente, foi incorporado uma fonte complementar de dados econômicos do IBGE contendo o PIB. Como a estrutura da tabela era divergente das demais, optou-se por manter em notebooks separados.

DataSUS

Foram realizados diversos testes para verificar de qual forma o Databricks free edition faria a leitura dos dados. Para isso, foi selecionado um dos arquivos carregados no ambiente, observando o comportamento e modificando o código ao longo do processo.



```
#Teste de verificação de leitura do arquivo
#Troca do .option("encoding", "UTF-8") para "ISO-8859-1"
arquivo = "/Volumes/mvp_1/bronze/dados_brutos/TVD1_ANO_MUNICIPIO.csv"

df_teste = (
    spark.read
        .option("header", "true")
        .option("inferSchema", "false")
        .option("sep", ";")
        .option("encoding", "ISO-8859-1")
        .csv(arquivo)
)

display(df_teste.limit(10))
```

> [See performance \(1\)](#) ✓ Checked for improvements


> df_teste: pyspark.sql.connect.dataframe.DataFrame = [Município: string, 1999: string ... 24 more fields]

	^c Município	^c 1999	^c 2000	^c 2001	^c 2002	^c 2003	^c 2004	^c 2005	^c 2006	^c 2007
1	110001 ALTA FLORESTA D'OESTE	0	10,21	91,44	90,02	111,54	97,46	96,02	111,13	146,45
2	110002 ARIQUEMES	0	22,46	128,40	128,31	155,59	120,76	127,45	124,32	169,74
3	110003 CABIXI	0	40,78	100,70	90,78	117,02	273,20	103,33	108,57	98,97
4	110004 CACOAL	0	19,24	97,79	103,62	115,58	102,59	106,54	106,21	107,00

Figura 1.1 – Teste de verificação de leitura do primeiro arquivo

Nesse teste, o arquivo foi lido com erro de caractere por conta da utilização do *encoding* “UTF-8”, sendo necessária a mudança para o *encoding* “ISO-8859-1” que inclui acentuação.

Foi utilizada a função `printSchema` para verificar os tipos de dados utilizados para o DataSUS.




```
df_teste.printSchema()

root
|-- Município: string (nullable = true)
|-- 1999: string (nullable = true)
|-- 2000: string (nullable = true)
|-- 2001: string (nullable = true)
|-- 2002: string (nullable = true)
|-- 2003: string (nullable = true)
|-- 2004: string (nullable = true)
|-- 2005: string (nullable = true)
|-- 2006: string (nullable = true)
|-- 2007: string (nullable = true)
|-- 2008: string (nullable = true)
|-- 2009: string (nullable = true)
```

Figura 1.2 – Exemplo de verificação de tipo de dados utilizados

Ao tentar criar a tabela no ambiente ocorreu um erro onde os nomes das colunas tinham espaços vazios, mas esse erro foi tratado ao subir as tabelas. Primeiramente foi feito a gravação da tabela `tvdl_município` e posteriormente as demais com uma função:



```
#Função para leitura e gravação dos arquivos
def carregar_bronze(nome_arquivo, nome_tabela):
    caminho = f"/Volumes/mvp_1/bronze/dados_brutos/{nome_arquivo}"


    #Leitura do arquivo original
    df = (
        spark.read
        .option("header", "true")
        .option("inferSchema", "false")
        .option("sep", ";")
        .option("encoding", "ISO-8859-1")
        .csv(caminho)
    )

    #Padronização técnica dos nomes das colunas
    #Remove espaços das extremidades e substitui espaços internos por "_"
    novos_nomes = [
        coluna.strip().replace(" ", "_")
        for coluna in df.columns
    ]

    df = df.toDF(*novos_nomes)
    #Gravação como tabela Delta
    (
        df.write
        .format("delta")
        .mode("overwrite")
        .saveAsTable(f"mvp_1.bronze.{nome_tabela}")
    )

    print(f"Tabela {nome_tabela} criada com sucesso.")
```

Figura 1.3 – Função de leitura e gravação dos arquivos DataSUS



```
# Arquivos restantes que serão carregados

arquivos_bronze = {
    "TVD1_ANO_UF.csv": "tvd1_uf",
    "TVD1_ANO_REGIAO.csv": "tvd1_regiao",

    "TVD2_ANO_MUNICIPIO.csv": "tvd2_municipio",
    "TVD2_ANO_UF.csv": "tvd2_uf",
    "TVD2_ANO_REGIAO.csv": "tvd2_regiao",

    "Tetraviral_SCRVZ_ANO_MUNICIPIO.csv": "scrvez_municipio",
    "Tetraviral_SCRVZ_ANO_UF.csv": "scrvez_uf",
    "Tetraviral_SCRVZ_ANO_REGIAO.csv": "scrvez_regiao"
}

for arquivo, tabela in arquivos_bronze.items():
    carregar_bronze(arquivo, tabela)
```

> [See performance \(8\)](#) ✓ Checked for improvements

Tabela tvd1_uf criada com sucesso.
Tabela tvd1_regiao criada com sucesso.
Tabela tvd2_municipio criada com sucesso.
Tabela tvd2_uf criada com sucesso.
Tabela tvd2_regiao criada com sucesso.
Tabela scrvez_municipio criada com sucesso.
Tabela scrvez_uf criada com sucesso.
Tabela scrvez_regiao criada com sucesso.

Figura 1.4 - Execução da função para as tabelas restantes

Ainda na camada Bronze, foram feitas algumas modificações para leitura das tabelas a fim de entender melhor a qualidade dos dados, e nessa etapa foram encontradas algumas inconsistências entre os dados, por exemplo: um município a mais presente apenas na tabela tvd1_municipio, onde mais tarde confirmou-se ser um município extinto como próprio nome da linha sugere “431453 PINTO BANDEIRA (EXTINTO)”. Também foi verificado o período de dados disponíveis, onde para TVD1 temos dados de 1999 a 2022 e as demais vacinas somente de 2013 a 2022. Também foi verificada uma linha denominada Total.

Adicionalmente, foi verificada a existência de valores duplicados na coluna identificadora dos respectivos registros geográficos, bem como os valores acima de 100 e abaixo de 0 da cobertura vacinal. Por fim, finalizou-se com a transformação dos dados de *string* para *double*.

```
df.select(F.explode(F.array(*valores)).alias("cobertura"))
)

negativos = df_valores.filter(F.col("cobertura") < 0).count()
acima_100 = df_valores.filter(F.col("cobertura") > 100).count()

estatisticas = (
    df_valores
    .agg(
        F.min("cobertura").alias("minimo"),
        F.max("cobertura").alias("maximo")
    )
    .collect()[0]
)

print(
    f"{tabela}: "
    f"negativos={negativos} | "
    f"acima_100={acima_100} | "
    f"mínimo={estatisticas['minimo']} | "
    f"máximo={estatisticas['maximo']}"
)

> See performance (27) ✓ Checked for improvements

tvd1_municipio: negativos=0 | acima_100=65185 | mínimo=0.0 | máximo=9550.0
tvd1_uf: negativos=0 | acima_100=286 | mínimo=0.0 | máximo=6692.1
tvd1_regiao: negativos=0 | acima_100=63 | mínimo=0.0 | máximo=6692.1
tvd2_municipio: negativos=0 | acima_100=13241 | mínimo=0.0 | máximo=7400.0
tvd2_uf: negativos=0 | acima_100=6 | mínimo=23.02 | máximo=128.41
tvd2_regiao: negativos=0 | acima_100=0 | mínimo=35.53 | máximo=99.27
scrz_municipio: negativos=0 | acima_100=6423 | mínimo=0.0 | máximo=7250.0
scrz_uf: negativos=0 | acima_100=4 | mínimo=0.81 | máximo=129.99
scrz_regiao: negativos=0 | acima_100=0 | mínimo=2.1 | máximo=95.3
```

Figura 1.5 – Exemplo de teste realizado para verificação de qualidade dos dados

SIDRA/IBGE

Da mesma forma que os dados disponíveis nas tabelas obtidas do DataSUS foram apurados, os dados da SIDRA foram averiguados, confirmando número de municípios, tipos de coluna, períodos, se houveram valores nulos e entre outros.

```
#Verificação de quantidade de municípios, tipos de coluna e período
df_pib = spark.table("mvp_1.bronze.pib_municipio")

display(df_pib)

print(f"Linhas: {df_pib.count()}")
print(f"Colunas: {len(df_pib.columns)}")


df_pib.printSchema()

> See performance (2) ✓ Checked for improvements

> df_pib: pyspark.sql.connect.dataframe.DataFrame = [Cód.: string, Município: string ... 22 more fields]
```

Figura 1.6 – Exemplo de verificação da qualidade dos dados

Foi identificado um registro incomum referente a fonte de dados durante os testes realizados, sem correlação com a granularidade. Dessa forma, ele será tratado na camada Silver.



```
# Identificar o registro ausente

display(
  df_pib.filter(
    F.col("codigo_municipio_ibge").isNull() |
    F.col("municipio").isNull()
  )
)
```

	A ^B codigo_municipio_ibge	A ^B municipio	A ^B 2002	A ^B 2003	A ^B 2004
1	> Fonte: IBGE, em parceria com os Órgãos Estaduais de Estatística, Secretarias Estaduais de Governo e Superintendência da Zona Franca...	null	null	null	null

Figura 1.7 – Linha incomum pertencente a tabela do PIB municipal

Modelagem e Catálogo de dados

Silver

DataSUS

Na modelagem, a partir das identificações de tipo de dados e dos dados em si, foi realizada uma padronização dos mesmos. Conforme dito antes, os dados referentes à cobertura vacinal não foram agregados por média aritmética, uma vez que os territórios possuem populações alvos diferentes. Serão utilizados os indicadores disponíveis diretamente do DataSUS.

Nessa camada, foram realizadas as seguintes etapas:

- Limpeza, padronização e reestruturação dos dados oriundos das fontes originais;
- Transcrição das colunas que representavam o ano para linhas, onde cada registro passou a representar uma unidade geográfica e determinado ano;
- Remoção de registros de totalização;
- Padronização dos tipos de dados, tratamento dos separadores decimais e separação do código e dos nomes das unidades geográficas e
- Código Unidade da Federação derivado do identificador municipal.

SIDRA/IBGE

Para o PIB tivemos as seguintes padronizações:

- Conversão dos valores indisponíveis simbolizados por “...” para *null*
- Padronização e transcrição dos campos numéricos;
- Validação de valores nulos, duplicidade e granularidade dos conjuntos de dados;

Gold

Após as etapas de padronização realizadas na camada Silver, os dados foram consolidados na camada Gold, destinada ao armazenamento dos conjuntos de dados destinados às análises.

A consolidação foi feita de acordo com três granularidades: município, Unidade da Federação e Região. Para cada granularidade foi integrado um indicador referente a cada tipo de vacina. Também foram incorporados os dados do PIB provenientes do SIDRA/IBGE.

A figura abaixo representa o modelo lógico utilizado na criação da camada Gold. O Diagrama mostra como as tabelas tratadas na Silver foram combinadas utilizando o código geográfico e ano como chaves de integração.




Figura 2.1 – Modelo lógico de consolidação das tabelas Silver na camada Gold

Pipeline de Dados

O pipeline de dados foi dividido em ingestão, avaliação de qualidade, transformação e análise.

Etapa	Entrada	Operações	Saída
Ingestão Bronze	9 tabelas DataSUS	Leitura das bases	Tabelas Bronze
Qualidade Bronze	Tabelas Brutas	Contagens, <i>null</i> , domínios	Tabelas Bronze
Transformação Silver	Tabelas Bronze	<i>Unpivot</i> , tipagem, padronização e tratamento de ausências.	Tabelas Padronizadas
Bronze PIB	1 tabela SIDRA	Leitura da base, contagem, <i>null</i>	Tabela Bronze
Silver PIB	Tabela Bronze	Tipagem, padronização e tratamento de ausências.	Tabela Padronizada
Modelagem Gold	Tabela Silver	Integração dos indicadores por código geográfico e ano	Tabela analítica Gold
Análise	Tabelas Gold	Visualizações	Gráficos e respostas

Tabela 3.1 – Pipeline de dados

Qualidade de dados

Inicialmente a qualidade de dados foi iniciada já na camada Bronze, tentando identificar problemas existentes nas fontes antes da realização de quaisquer outras etapas. Sendo verificadas tabelas, presenças de valores indisponíveis ou nulos, duplicidade, tipo de dados e valores atípicos. Os principais problemas encontrados foram:

Problema identificado	Tratamento
Dados de cobertura armazenados originalmente em formato texto e com separador decimal por vírgula	Conversão e padronização para tipo numérico (double) na camada Silver
Estrutura dos dados em formato de coluna (ano)	Transformação para linhas, passando a representar cada combinação entre unidade geográfica e ano
Existência de registros denominados Total nas bases do DataSUS	Registros de totalização removidos durante a transformação para Silver
Código e nome do município armazenados na mesma coluna no DataSUS	Separação do código e do nome do município e derivação do código da UF
Cobertura vacinal superior a 100%	Os valores foram preservados conforme a fonte original, sem truncamento ou substituição, pois fazem parte dos indicadores disponibilizados pelo dataSUS
Diferença entre os identificadores municipais utilizados pelo DataSUS e pelo IBGE	Criação de uma chave compatível para possibilitar a integração entre as fontes
Valores de PIB indisponíveis representados por ... no SIDRA/IBGE	Conversão para NULL, sem imputação artificial de valores
Registro adicional de metadados na base de PIB	Remoção do registro durante a transformação para Silver
Diferenças históricas no cadastro municipal (município extinto)	Registros históricos foram preservados, evitando alterações arbitrárias na informação original
Possíveis duplicidades	Verificação para evitar duplicidade em JOINS

Tabela 4.1 – Qualidade de Dados

Foram identificados valores extremos acima de 100% em determinados municípios e ano, e por estarem nos dados originais disponibilizados pelo DataSUS optou-se pela preservação desses valores. Portanto, não foram aplicados limites artificiais ou substituições que alterassem a informação.

Também foi identificado na tabela do PIB valores sem correspondência ou sem valor econômico disponível. 95 registros sem valor do PIB foram descobertos, sendo que 74 eram registros existentes com valores ausentes da própria fonte, enquanto 21 eram

registros que não correspondiam a nenhuma combinação de municípios e ano encontrados na base. Esses registros foram mantidos como valores nulos.

Análise de Dados

Após tratamento, padronização e consolidação dos dados, foram realizadas diversas análises utilizando as tabelas da camada Gold. O objetivo é avaliar a evolução da cobertura vacinal da primeira e segunda dose da tríplice viral SCR e da tetraviral SCRvZ ao longo do período disponível.

Para as análises agregadas por região e Unidade Federativa utilizou-se diretamente os indicadores extraídos do DataSUS. Usando de referência para interpretação dos resultados, foi utilizada a métrica de 95% de cobertura vacinal, métrica recomendada estabelecida pelo Programa Nacional de Imunização (PNI).

Inicialmente foi considerada a cobertura da primeira dose da SCR, analisando a evolução entre as regiões brasileiras e identificando períodos de redução e diferença entre regiões.




Figura 5.1 – Gráfico da evolução da primeira dose da vacina tríplice viral por região

Pode-se observar que houve um aumento na vacinação até 2005, mantendo-se acima da meta PNI de 95% até meados de 2015, apesar de ocorrer oscilações entre os anos em diferentes regiões. A partir dessa data, observa-se uma redução na cobertura vacinal, não retornando até 2022 à meta recomendada.

Para avaliar as diferenças entre os três tipos de vacina e suas respectivas coberturas, foi considerado o período apenas de 2013 a 2022 pois a segunda dose da tríplice viral e a tetraviral só possuíam dados desses períodos. Os três períodos foram considerados separadamente, já que são imunizantes distintos.




Figura 5.2 – Gráfico da evolução da primeira dose da vacina tríplice viral por região de 2013 a 2022




Figura 5.3 – Gráfico da evolução da segunda dose da vacina tríplice viral por região de 2013 a 2022




Figura 5.4 – Gráfico da evolução da tetraviral SCRVR por região de 2013 a 2022

Analisando os três gráficos em conjunto podemos notar uma diferença entre as doses aplicadas. A TVD1 apresentou maior cobertura vacinal principalmente no início do período analisado (2013), sendo que a TVD2 registrou cobertura abaixo da TVD1 na maior parte dos casos. A SCRVRZ apresentou um decaimento acentuado no Nordeste e no Sudeste. Não é possível tirar maiores conclusões utilizando apenas esses dados.

Para complementar a comparação, foi medida a diferença entre as coberturas da primeira e segunda dose da tríplex viral no período de 2013 a 2022. A diferença foi calculada em pontos percentuais, onde valores positivos indicam que a cobertura da primeira dose foi superior à da segunda dose.




Figura 5.5 – Gráfico de diferença entre as coberturas vacinais da TVD1 e TVD2

Constata-se que a cobertura da primeira dose permaneceu superior em relação a da segunda durante o período analisado, embora a diferença tenha variado ao longo dos anos. Em 2013 foi observada uma grande discrepância das regiões Norte, Nordeste e Centro-Oeste, já em 2020 essa diferença voltou a crescer nas regiões Norte e Centro-Oeste.

Foi elaborado um mapa de calor da cobertura de TDV1 entre 2013 e 2022, permitindo verificar diferenças geográficas e temporais na cobertura da vacina.




Figura 5.6 – Mapa de calor da cobertura vacinal da primeira dose da tríplice viral

No mapa de calor podemos notar uma mudança no padrão da cobertura regional ao longo do tempo. Em 2013 e 2014, todas as regiões atingiram a meta da cobertura vacinal recomendada, entretanto nos anos seguintes observa-se um decaimento da cobertura, com intensidades diferentes. A partir de 2015 ocorreu uma maior redução, e as regiões apresentaram cobertura abaixo de 95% com a região norte apresentando os menores valores. Esse mapa consegue exemplificar as diferenças territoriais da aplicação da vacina.

Após a análise regional, foi selecionado o ano de 2022 para comparação da cobertura da primeira dose da tríplice viral entre os Estados, com a finalidade de entender melhor o comportamento no intervalo escolhido.




Figura 5.7 – Gráfico de cobertura vacinal por Estado em 2022

Em 2022, nenhum dos 27 Estados do Brasil alcançou a meta de vacinar 95% do público alvo, apesar de Santa Catarina chegar bem próximo, com 94,9%, seguido por Mato Grosso do Sul com 91,83% e Distrito Federal com 90,23%. O Amapá registra a menor cobertura vacinal com valor de 61,33%.

Para finalizar, o seguinte gráfico abaixo demonstra a proporção dos municípios que atingiram cobertura da primeira dose da vacina igual a 95% em cada ano, constatando a distribuição dos municípios em relação ao valor de referência adotado.




Figura 5.8 – Gráfico de proporção dos municípios que atingiram a meta de cobertura vacinal da primeira dose da vacina

Nos primeiros anos analisados cresceu o número de municípios que alcançaram esse patamar, com oscilações ao longo dos anos. A partir de 2015, observa-se uma redução acompanhando a queda observada na análise regional. Portanto pode-se notar que a redução não ocorreu apenas em localidades isoladas, e sim acompanhou as tendências regionais.

Respondendo as questões levantadas

Voltando ao objetivo principal, será verificado se os questionamentos foram respondidos de forma total, parcial ou não foram respondidos.

1. Como se deu a evolução da cobertura vacinal contra o sarampo no Brasil ao longo dos anos?

As análises realizadas demonstraram que a cobertura vacinal contra o sarampo apresentou diversas oscilações ao longo do período estudado. No início do período, de 2000 a 2010 a cobertura da primeira dose da vacina estava igual ou acima da meta estabelecida pelo Programa Nacional de Imunizações, para quase todas as regiões brasileiras. Entretanto, a partir de 2015 foi notada a tendência ao declínio da cobertura vacinal, abaixo da meta de 95%. Portanto, houve uma mudança significativa no

comportamento ao longo da série histórica, tendo um declínio mais acentuado próximo dos anos mais recentes.

2. Quais Estados apresentaram maiores e menores índices de vacinação ao longo do período?

Aqui será respondido de forma parcial, pois inicialmente procurava-se responder a pergunta ao longo de todo o período analisado, entretanto, devido ao escopo e ao tempo disponível para o desenvolvimento do MVP, optou-se por concentrar a comparação no ano de 2022, último ano disponível para análise.

A análise mostrou diferença significativa no índice de vacinação entre os Estados brasileiros. Em 2022, Santa Catarina aparece em primeiro lugar com 94,94% e apesar de ocupar a primeira posição do ano referido, ainda estava abaixo da meta do PNI. Já por último temos o estado do Amapá com 61,33% da cobertura vacinal, um número bem baixo em relação à meta do PNI.

3. Quais regiões brasileiras tiveram uma cobertura vacinal mais precária?

Os valores de cobertura variam ao longo dos anos, porém é possível notar uma tendência da Região Norte ser menor que as demais regiões para um mesmo período, expondo uma situação particularmente crítica em relação às outras regiões.

4. Quais anos a cobertura vacinal brasileira ficou abaixo da estabelecida para vacinação?

De 2020 a 2022, todas as regiões brasileiras apresentaram cobertura da primeira dose da vacina inferior a 95%, ainda que haja uma recuperação em 2022, é evidente uma recuperação generalizada para todas as regiões.

5. Quais diferenças são observadas entre SCR D1, SCR D2 e SCR VZ?

Essa pergunta surgiu durante as análises dos dados. Considerando o período estudado, os três tipos de vacina tiveram bastante divergências na adesão das vacinas.

A diferença entre a primeira dose da SCR e a segunda dose da SCR, variou ao longo dos anos, em determinado momento foi observado diferenças mais acentuadas entre as doses.

Já a SCR VZ apresentou um comportamento distinto das outras vacinas, por se tratar de outro imunobiológico, foi analisado de forma separada.

Os três indicadores não apresentaram comportamentos idênticos ao longo do período.

6. Houve períodos de quedas seguidas na cobertura vacinal no Brasil?

Sim, notou-se períodos de redução consecutiva da cobertura vacinal, embora não de maneira uniforme. Como dito anteriormente, a partir de 2015 houve uma redução significativa e quase constante da cobertura.

7. Análise dos PIBs das regiões e/ou Estado em relação à cobertura da vacinação.

Essa análise inicialmente visava verificar uma correlação entre o PIB das regiões geográficas com a cobertura vacinal das 3 doses, estruturou-se e

foi incorporado ao pipeline. Porém, nas primeiras análises não se mostrou algo simples, como pensado a princípio, exigindo mais detalhes e dados para que pudesse ter alguma correlação. Dessa forma, optou-se por não aprofundar essa análise no presente MVP, mantendo, entretanto, os dados de PIB integrados ao pipeline para possibilitar análises futuras.

Autoavaliação

Fazer este projeto foi um desafio maior do que eu estava esperando. Apesar de trabalhar na área e lidar diariamente com diversos bancos de dados, vários desses conhecimentos aprendi de forma prática, sem o embasamento teórico adequado. A maior dificuldade foi levantar os questionamentos, uma vez que eu procurava dados de qualidade ou confiáveis e não os encontrava. Então me deparei com o DataSUS, compreendendo a importância da vacinação, vinculado aos casos de sarampo na cidade de São Paulo. Acredito que por falta de afinidade com o Databricks Free Edition e até mesmo suas limitações (uma vez que eu estou acostumada a usar o Cloudera da empresa em que trabalho) eu levei um tempo superior que o estimado. Além dos testes que geralmente eu realizo em SQL no ambiente Impala, me vi um pouco indecisa se mantinha nos notebooks ou se deixava apenas documentado, mas preferi deixá-los registrado. Outra diferença que optei me afastando do meu costume foi utilizar o Python e PySpark em detrimento do SQL. Desta forma me empenhei em executar a utilização dos notebooks como um organizador de ideias, para ficar maior facilidade em me localizar durante o trabalho.

Penso que foi bastante proveitoso o surgimento de novas perguntas ao longo do trabalho e ao longo das análises e igualmente frustrante também, principalmente nas limitações de base. Acredito que o relatório tenha ficado bem repetitivo e se me ocorresse mais tempo disponível provavelmente teria optado por outras perguntas ou acrescentado mais variáveis as análises. Na questão dos gráficos, utilizei IA para recomendação de outros gráficos que não fossem de linha, porém o resultado não me agradou e é necessário que eu aprofunde meus conhecimentos nessa área.

Acredito que tenha atingido grande parte das minhas expectativas, mas também que tem muito espaço para aprimorar, adicionar e melhorar.

Referências

BRASIL. Ministério da Saúde. Manual Módulo de Controle Externo – MCE SIOPS. Brasília: Ministério da Saúde, 2015. Disponível em: [Manual](#). Acesso em: 20/09/2026.

BRASIL. Ministério da Saúde. Departamento de Informática do SUS (DATASUS). *Imunizações – Cobertura – Brasil*. Sistema de Informações do Programa Nacional de Imunizações (SI-PNI/TABNET). Brasília: Ministério da Saúde. Disponível em: [DATASUS – Imunizações](#). Acesso em: 13/09/2026.

BRASIL. Ministério da Saúde. Boletim Epidemiológico Mercosul – COVIGSAL. Brasília: Ministério da Saúde, 2025. Disponível em: [Boletim Epidemiológico – Ministério da Saúde](#). Acesso em: 20/09/2026.

IBGE – Instituto Brasileiro de Geografia e Estatística. *Sistema IBGE de Recuperação Automática – SIDRA. Tabela 5938: Produto Interno Bruto dos Municípios*. Rio de Janeiro: IBGE. Disponível em: [SIDRA – Tabela 5938](#). Acesso em: 21/09/2026.